

烹茗 AI 客服系统 · 使用说明书

一套开箱即用的茶叶电商 AI 客服。clone 到本地，配一个 LLM API key，几条命令即可对话。

一、环境与依赖

项	要求
Python	3.11+
操作系统	macOS / Linux / Windows (WSL 推荐)
LLM 接入	OpenRouter (一个 key 通吃, 推荐) 或原生 Anthropic
资料采集 (可选)	Jina Reader (免费) / Tavily / Firecrawl 任一
端口	8000 (可改)
体积	代码 + 模型 + 索引 < 200MB

二、5 分钟启动

1. 安装依赖

```
git clone <仓库地址>
cd xim
python3 -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt
```

首次安装会下载 `BAAI/bge-small-zh-v1.5` (约 90MB), 用于中文向量化。

2. 配置 API Key

复制 `.env.example` 为 `.env`, 至少填一项 LLM key:

```
cp .env.example .env
```

二选一

OPENROUTER_API_KEY=sk-or-v1-xxxxxxxxxxx

推荐：一个 key 用所有 Claude 模型

ANTHROPIC_API_KEY=sk-ant-xxxxxxxxxxx

或：原生 Anthropic

可选模型覆盖（默认 sonnet 4.5 抽取 + haiku 4.5 对话）

XIMING_MODEL=anthropic/claude-sonnet-4.5

XIMING_CHAT_MODEL=anthropic/claude-haiku-4.5

可选：资料采集 API（不采集可不填）

JINA_API_KEY=jina_XXXXXXX

TAVILY_API_KEY=tvly-XXXXXXX

FIRECRAWL_API_KEY=fc-XXXXXXX

3. 启动

```
uvicorn app:app --host 0.0.0.0 --port 8000
```

启动时若发现 `data/vector.db` 不存在，会自动从 `data/knowledge/nodes.jsonl`（仓库自带 973 节点）重建向量索引，约 30 秒。看到这行就是好了：

```
INFO KB ready · 973 nodes · embed=bge-small-zh-v1.5 · llm=openrouter:claude-sonnet
```

4. 打开浏览器

- 客服对话：<http://localhost:8000/>
 - 知识库浏览：<http://localhost:8000/admin>
 - 健康检查：<http://localhost:8000/healthz>
 - 系统统计：<http://localhost:8000/stats>
-

三、界面与功能

3.1 客服对话页



页面元素： – 左上角：品牌标识「烹茗 AI 客服 · 小茗」与副标题「朱子后人 · 制茶世家」 – 右上角：实时统计 **973 节点 · 106 SKU** + embedding 模型 + LLM backend 显示 – 气泡区：欢迎语 + 后续多轮对话 – 底部输入框：支持回车发送，按钮发送 – 快捷追问芯片：「送领导礼盒预算 1500」「牛魁肉桂多少钱」「白毫银针水温」「茶饼发霉怎么办」「孕妇能喝茶吗」一键发起常见问题 – 开发者模式：勾选后回复下方显示 **intent / 置信度 / cite 节点 ID / 工具调用** 调试信息

3.2 知识库浏览 (Admin)

熹茗 KB 浏览器

← 返回客服

统计 JSON

查看待人审 →

973 节点 · 106 SKU · 岩茶 295 · 白茶 236 · 未知 98 · 普洱 85 · 红茶 57 · 茉莉花茶 43 · 绿茶 39 · 乌龙茶 36 · 茶点 29 · 普洱茶 28 · 陈皮 22 · 通用 3 · 综合品类 1 · 其他茶类 1

语义检索 (同时跑 BM25 + bge 向量), 留空则按筛选浏览全库

全部品类

全部 node_type

全部域名

☐ 仅 SKU 详情页

搜索

共 973 条结果 (按筛选浏览) · 当前展示 50 条

doc_id	分类	类型	权威	检索分	正文 / 来源
424436e5fa731d41	通用	commerce_aftersale_sop	*****	—	熹茗茶业的售后处理路径: ① 由购买门店第一时间对接 (全国近 400 家专卖店) ② 总部加盟热线 4008811977 升级处理 ③ 食品质量问题 (受潮/发霉/串味/虫蛀等) 48 小时内补寄同款或全额退款, 运费门店承担 ④ 撬过的茶饼/紧压茶不支持 7 天无理由退换, 但质量问题不在此限 https://www.ximingcha.com/store.aspx
b3ccbcdec602c95d	通用	commerce_logistics	*****	—	熹茗以线下加盟门店为主要销售渠道, 全国近 400 家专卖店覆盖北京、上海、广州、深圳、苏州、成都、长沙、西安等 20+ 省市。如需查询附近门店或电话购买, 可拨打总部加盟热线 4008811977 或访问官网门店分布页 ximingcha.com/store.aspx 查询。 https://www.ximingcha.com/store.aspx
fd4a06bb794f6d8	通用	commerce_order	*****	—	熹茗官方联系方式: ① 加盟热线 (含产品咨询/订购/售后升级) 4008811977 ② 官网 ximingcha.com 提供门店分布与产品介绍 ③ 总部地址: 福建省福州市台江区宁化街道江滨西大道 100 号融侨中心 3501-01 单元 ④ 微信公众号「熹茗茶业」「熹茗茶事」(页脚二维码) https://www.ximingcha.com/
000109c36bf9a18e	白茶	product_grade	****	—	牛饼·福山牡丹王为一级白牡丹, 芽头肥壮, 符合高等级白茶的外形与内质标准, 适合长期收藏陈化。 https://www.ximingcha.com/showPro.aspx?id=786113
0037cb651e451376	茉莉花茶	product_sku	****	—	子茉十管香针是熹茗茉莉花茶的顶级款, 零售价 1880 元/罐。采用非遗大师监制工艺, 经过十管流程, 茉莉花香浓郁持久, 属于高端礼品或资深茶友收藏级别。 https://www.ximingcha.com/proList.aspx?oid=837733
00beb67e35fb5cd3	岩茶	product_category	****	—	丛味百年系列属于武夷岩茶中的老枞水仙品类。水仙是武夷岩茶四大名丛之一, 老枞水仙指树龄较长的水仙茶树所产, 具有独特的「枞味」特征, 包括青苔味、

页面元素： - 顶栏统计：节点总数 + 类型分布 + SKU 数量 - 顶部筛选：全部品类 / 全部 node_type / 来源 host / 关键词搜索 - 列表列： node_id / 类型 / 品类 / 来源 / 信任级 / 节点正文摘要 - 适用场景：客服培训、运营自查"AI 知识库到底有哪些东西"、bad case 溯源

3.3 系统统计 /stats

美观输出 ☐

```
{
  "kb_nodes": 973,
  "sku_pages": 106,
  "by_category": {
    "岩茶": 295,
    "白茶": 236,
    "未知": 98,
    "普洱": 85,
    "红茶": 57,
    "茉莉花茶": 43,
    "绿茶": 39,
    "乌龙茶": 36,
    "茶点": 29,
    "普洱茶": 28,
    "陈皮": 22,
    "通用": 3,
    "综合品类": 1,
    "其他茶类": 1
  },
  "by_host_top5": {
    "www.ximingcha.com": 973
  },
  "embed_model": "BAAI/bge-small-zh-v1.5",
  "llm_backend": "openrouter",
  "llm_model": "anthropic/claude-sonnet-4.5",
  "llm_ready": true,
  "anthropic_key_set": false,
  "openrouter_key_set": true
}
```

JSON 输出 (节选):

```
{
  "kb_nodes": 973,
  "sku_pages": 106,
  "by_category": {
    "岩茶": 295, "白茶": 236, "普洱": 85, "红茶": 57,
    "茉莉花茶": 43, "绿茶": 39, "乌龙茶": 36, "茶点": 29
  },
  "by_host_top5": { "www.ximingcha.com": 973 },
  "embed_model": "BAAI/bge-small-zh-v1.5",
  "llm_backend": "openrouter",
  "llm_model": "anthropic/claude-sonnet-4.5",
  "llm_ready": true
}
```

四、对话效果展示

下面是真实运行 `curl` 调用 `/chat` 接口得到的回复，三类场景全部由当前部署版本作答。

4.1 真实对话渲染（完整 UI 效果）

场景一 · 产品推荐

想买点茶送领导，预算800左右，他平时喝岩茶多

茗 预算 800 元送懂岩茶的领导，我建议：

正心系列岩茶（250g）
正岩山场品质稳定，办公室好取用，日常消耗款体现实用心意。价格约 250-300 元。

牛魁肉桂
岩茶经典，香气醇厚，领导熟悉的口味。这个价位能配到品质不错的款式。

两款可搭配送礼，或单选一款预留预算配礼盒。具体款式和当前价格，我帮您查一下？

意图: recommend · 置信度 0.737 · 引用 3 节点

场景二 · 冲泡指导

你们的肉桂我泡总是发苦，怎么办？

茗 肉桂本身辛锐，容易冲苦。试试这些参数：

投茶 3g / 水温 95°C / 前三道 5 秒快出（不要坐杯） / 之后逐道加 3-5 秒

关键是前三道要快，把辛锐的物质快速冲出，后面茶汤会变顺。水温也可降到 90°C 试试。

你用的什么茶具，盖碗还是玻璃杯？

意图: brewing · 置信度 0.858 · 引用 3 节点

场景三 · 售后处理（含多轮场景粘性）

我昨天收到的白牡丹饼，撬开里面有点发霉！

茗 非常抱歉！收到发霉的茶是我们的责任，我们来立即帮您解决。

请提供以下信息，我好为您快速处理：

1. 订单号是多少？
2. 能发一张发霉部分的照片吗？

确认后我们支持 48 小时内补寄或全额退款，运费由我们承担。

意图: aftersale · 置信度 0.719

白毫银针

茗 我理解您现在心情不好。请问您说的是白毫银针也发霉了，还是您想要退掉这个白牡丹饼、换白毫银针？

先把白牡丹的订单号和发霉照片给我，我们一起处理这个问题。

意图锁定: aftersale · 置信度 0.870 · 多轮粘性命中

4.2 场景一 · 产品推荐

输入：

```
curl -sS -X POST http://localhost:8000/chat \  
-H "Content-Type: application/json" \  
-d '{"session_id":"d-rec","message":"想买点茶送领导，预算800左右，他平时喝岩茶多"}'
```

返回：

预算 800 元送懂岩茶的领导，我建议：

****正心系列岩茶**** (250g)

正岩山场品质稳定，办公室好取用，日常消耗款体现实用心意。价格约 250-300 元。

****牛魁肉桂****

岩茶经典，香气醇厚，领导熟悉的口味。这个价位能配到品质不错的款式。

两款可搭赠送礼，或单选一款预留预算配礼盒。具体款式和当前价格，我帮您查一下？

intent=recommend · confidence=0.737 · cite=3 节点

要点：基于 RAG 召回的真实 SKU 给出 1-2 款 + 主要卖点 + 一句反问，不开场白、不堆栈 5 款。

4.3 场景二 · 冲泡指导

输入：你们的肉桂我泡总是发苦，怎么办？

返回：

肉桂本身辛锐，容易冲苦。试试这些参数：

投茶 3g / 水温 95℃ / 前三道 5 秒快出（不要坐杯） / 之后逐道加 3-5 秒

关键是前三道要快，把辛锐的物质快速冲出，后面茶汤会变顺。

水温也可降到 90℃ 试试。

你用的什么茶具，盖碗还是玻璃杯？

intent=brewing · confidence=0.858 · cite=3 节点

要点：先一句诊断（辛锐/坐杯/水温），再给参数四件套，最后反问器具以便精调。

4.4 场景三 · 售后处理（多轮场景粘性）

第 1 轮：

输入：我昨天收到的白牡丹饼，撬开里面有点发霉！

返回：

非常抱歉！收到发霉的茶是我们的责任，我们来立即帮您解决。

请提供以下信息，我好为您快速处理：

1. 订单号是多少？
2. 能发一张发霉部分的照片吗？

确认后我们支持 48 小时内补寄或全额退款，运费由我们承担。

intent=aftersale · confidence=0.719

第 2 轮（同 session_id，用户只回复 2 个字）：

输入：白毫银针

返回：

我理解您现在心情不好。请问您说的是白毫银针也发霉了，还是您想要退掉这个白牡丹饼、换白毫银针？

先把白牡丹的订单号和发霉照片给我，我们一起处理这个问题。

intent=aftersale · confidence=0.870 · 多轮粘性命中

要点：第 2 轮 RAG 朴素分类会把“白毫银针”误判为产品推荐场景，开始介绍这款新茶。系统通过 agent/orchestrator.py 检测历史含“发霉/订单号/退货”等售后关键词，强制锁定 aftersale 意图，正确把“白毫银针”理解为“用户要退/换的茶品名”，并在话术里 disambiguate 两种可能的语义。这就是售后场景“信息凑齐前不切场景”的工程实现。

五、HTTP API 完整列表

路径	方法	用途
/	GET	Web 客服界面 (web/index.html)
/admin	GET	KB 浏览界面
/chat	POST	同步对话 (JSON 请求 + JSON 响应)
/chat/stream	POST	流式对话 (SSE, TTFT $\approx$ 2.5s)
/nodes	GET	列出全部知识节点 (带 query / type / category 筛选)
/pending	GET	列出契约校验失败、待人审节点
/healthz	GET	健康检查
/stats	GET	节点 / SKU / 模型 / 后端状态统计

5.1 /chat 请求格式

```
{
  "session_id": "user-12345",
  "message": "白毫银针怎么泡? ",
  "channel": "taobao"
}
```

5.2 /chat 响应格式

```
{
  "reply": "白毫银针 90°C.....",
  "session_id": "user-12345",
  "cite": ["abc123", "def456"],
  "need_human": false,
  "intent": "brewing",
  "confidence": 0.85,
  "tool_calls": [],
  "raw_violations": [],
  "next_action": null
}
```

5.3 流式调用（前端推荐）

```
const res = await fetch('/chat/stream', {
  method: 'POST',
  headers: {'Content-Type': 'application/json'},
  body: JSON.stringify({session_id, message})
});
const reader = res.body.getReader();
const dec = new TextDecoder();
while (true) {
  const {done, value} = await reader.read();
  if (done) break;
  // 按 SSE 格式解析 data: {...}\n\n
}
```

六、命令行工具（cli.py）

```
# 终端对话
python cli.py chat

# 检索测试（不调用 LLM，只看 RAG 结果）
python cli.py search "白毫银针的水温"

# 重建向量索引（修改 nodes.jsonl 后用）
python cli.py reindex

# 跑黄金集回归
python cli.py eval
```

七、知识库刷新

7.1 手动跑流水线

```
# 完整流水线：搜索 → 抓取 → LLM 抽取 → 入库
python -m ingestion.pipeline --mode llm

# 只重建索引（已有 nodes.jsonl）
python -m ingestion.pipeline --reindex-only

# 不用 LLM，按 markdown 段落切分（无 API key 时降级方案）
python -m ingestion.pipeline --mode section
```

跑完后产物：

- `data/knowledge/nodes.jsonl` — 主知识库（已入 git）
- `data/knowledge/pending_review.jsonl` — 校验未通过的待人审节点
- `data/knowledge/manifest.json` — 状态摘要
- `data/vector.db` — Milvus Lite 向量索引（不入 git，启动重建）

7.2 自动周度刷新

`.github/workflows/ingest.yml` 每周日北京时间 03:00 自动跑一次，将 diff 后的 `nodes.jsonl` 提交回 main 分支，并把产物上传为 GitHub Artifact 保留 30 天。

可通过 GitHub Actions → "周期性知识库刷新" → "Run workflow" 手动触发，可选 `mode=llm` 或 `mode=section`。

八、Docker 部署

```
docker compose up -d
```

`docker-compose.yml` 已配置： - 端口 8000 → 容器 8000 - `.env` 自动注入 - `data/` 卷挂载，索引持久化 - 多阶段构建（`Dockerfile`）预装 bge 模型，镜像约 1.2GB

九、常见问题（FAQ）

Q1: 启动报 `LLM key not set`

A: 检查 `.env`，至少填 `OPENROUTER_API_KEY` 或 `ANTHROPIC_API_KEY` 一项。`.env.example` 有模板。

Q2: 第一次启动很慢

A: 在下载 `bge-small-zh-v1.5` 模型（约 90MB），后续启动会用本地缓存，秒开。

Q3: 回复速度慢 / 等很久才出第一个字

A: 用流式接口 `/chat/stream` 而不是 `/chat`。同步接口要等 LLM 全部生成完才返回，流式接口首字 ~2.5s。Web UI 默认就是流式。

Q4：怎么换更便宜或更强的模型？

A：改 `.env`：

```
XIMING_CHAT_MODEL=anthropic/claude-haiku-4.5    # 便宜，默认
XIMING_CHAT_MODEL=anthropic/claude-sonnet-4.5    # 准确度更高
XIMING_MODEL=anthropic/claude-sonnet-4.5         # 抽取用，建议 sonnet
```

重启即生效。

Q5：怎么加新的 SKU 进知识库？

A：两种方式：1. 在 `ingestion/sources.yaml` 的 `seed_urls` 里加新页面 URL，跑 `python -m ingestion.pipeline --mode llm`。2. 直接编辑 `data/knowledge/nodes.jsonl` 追加 JSON 行，跑 `python cli.py reindex`。

Q6：合规过滤误伤了正常话术怎么办？

A：编辑 `safety/compliance_filter.py`，调整正则。常见绝对化用语已加上下文判断（如 "最佳" 在 "110ml 盖碗最佳" 这种参数语境下不触发）。

Q7：怎么测准确率？

A：跑 `python cli.py eval` 或 `python eval/run_eval.py`，会用 `eval/golden_set.jsonl` 10 题黄金集回归。当前线上版本通过率 8/10。生产可扩到 ≥ 300 题。

Q8：能接淘宝/抖店真实订单 API 吗？

A：tools/business_tools.py 已留出 `order_query / logistics_query / create_aftersale_ticket / transfer_to_human` 四个接口位置，目前是 mock 返回示例数据。生产对接你的 ERP/电商 API 即可，不用动 RAG 和 prompt。

十、目录速查

xim/	
├─ app.py	FastAPI 入口 (含 SSE 流式)
├─ cli.py	命令行工具
├─ agent/	会话编排 + LLM 双后端封装
├─ ingestion/	数据采集 (schema / sources / multi-API / 抽取 / 流水线)
├─ retrieval/	向量库 + 混合检索
├─ prompts/	4 个提示词文件 (基座 + 3 场景)
├─ safety/	合规过滤
├─ tools/	Tool Use 接口
├─ eval/	黄金集 + 回归脚本
├─ web/	单文件聊天界面 + Admin
├─ data/knowledge/	nodes.jsonl 入库 (已含 973 节点)
├─ docs/screenshots/	本说明书使用的截图
└─ .github/workflows/	CI + 周度刷新

十一、技术参数速查

项	值
知识节点	973 个 / 17 类 / 6 大类
SKU 覆盖	106 款
数据源洁净度	100% 来自 ximingcha.com (host 白名单)
向量模型	BAAI/bge-small-zh-v1.5 (512 维)
向量库	Milvus Lite (4MB 文件)
关键词召回	BM25Okapi + jieba 分词
抽取模型	Claude Sonnet 4.5 (OpenRouter)
对话模型	Claude Haiku 4.5 (流式)
流式 TTFT	≈ 2.5 秒
黄金集通过率	8/10
会话记忆	内存 LRU, 500 会话 / 1h TTL
合规防线	5 层 (采集 / 检索 / Prompt / 输出 / 评测)

有问题? 查看 [README.md](#) 或直接打开 [面试答卷.md](#) 查看架构说明。