

烹茗电商 AI 客服搭建方案

本文档对应仓库即一套完整可运行的实现：`pip install -r requirements.txt && uvicorn app:app` 即可启动。数据现状：973 个结构化知识节点 / 17 种节点类型 / 100% 来自 ximingcha.com 官网。

一、核心知识节点梳理

烹茗主营岩茶、白茶、红茶等多品类，知识分散在飞书文档、官网详情页、销售话术中。客服场景下高频被问到的内容，按"产品决策路径 + 售后流程"两条主线归纳为 **6 大类共 24 个知识节点**（落地为 `ingestion/schema.py`，每个节点都有"必填字段 / 可选字段 / 文本契约"三段约束）。

大类	节点类型	业务用途
产品基础	product_category 品类（岩茶/白茶/红茶...）	用户初步定品类
	product_sku 单品（含规格、价位、包装）	推荐与下单
	product_origin 山场产区（三坑两涧、太姥山、桐木关）	解释价格差异
	product_grade 等级与年份（特级 / 3 年老白茶）	老茶溢价说明
	product_scene 适用场景（自饮、商务送礼、节日礼）	礼品话术
工艺口感	process_craft 工艺（萎凋、做青、焙火轻重）	卖点解释
	process_aroma 香型（花香、果香、奶香、蜜香）	风味偏好匹配
	process_flavor 滋味（醇厚、回甘、岩骨花香）	风味描述
	process_compare 同类对比	选择困难时使用
冲泡指导	brewing_params 投茶量/水温/出汤时间/可冲次数	参数硬数据
	brewing_vessel 器具建议（盖碗 / 紫砂 / 飘逸杯）	配套推荐
	brewing_category_tip 不同品类要点（岩茶快出汤 vs 白茶可煮）	差异化建议
	brewing_troubleshoot 苦涩/味淡/串味的诊断	问题排查
饮用建议（合规敏感）	advice_general 一般饮用感受（提神、解腻）	不含疗效宣称
	advice_population 适宜/不宜人群（孕妇、失眠、空腹）	安全话术
	advice_constitution 体质参考（温/凉性）	仅作参考
	advice_storage 储存与保质期	高频咨询
交易售后	commerce_order 下单/支付/赠品	售前问答
	commerce_logistics 物流时效/发货地	时效查询
	commerce_return_policy 7 天无理由的食品类条款	售后政策
	commerce_aftersale_sop 破损/漏发/串味/发霉处理 SOP	售后流程
	commerce_membership 评价/复购/会员积分	复购引导
品牌信任	brand_story 品牌故事、获奖、SC 资质、检测报告	信任建立

大类	节点类型	业务用途
	brand_collab 联名款 / 大师款 / 限量款	高端礼品

为什么要做结构化节点而非纯文本切片： – 茶行业专名歧义重（"肉桂"既是茶也是香料、"老枞"="老丛"），结构化字段 + 元数据过滤可避免串类目幻觉。 – 价格、库存、物流是高频变动数据，必须从向量库剥离走 API（见第三部分 Tool Use）。 – 合规字段（sensitive: true）让违规风险在数据层就被标记，不等生成阶段才拦截。

二、利用 AI 工具获取资料文档

题目场景下资料分散在飞书 / 官网 / 销售话术等多处。本方案以 AI API 编排 + LLM Schema 抽取 为核心，全程不写 BeautifulSoup 规则解析，用 AI 替代传统爬虫的"看网页+写字段映射"工作。

2.1 数据源策略

ingestion/sources.yaml 定义白名单： – host_allowlist: ximingcha.com / ximingtea.com / gyfcgl.com，非白名单一律丢弃。 – 131 条种子 URL：113 条 SKU 详情页 + 18 条品牌/资讯/联系页。 – 不采 UGC（小红书/知乎/搜狐）：客服场景下 UGC 对功效宣称的污染风险远大于价值，宁缺毋滥。 – 飞书文档可作为另一路 source（飞书 OpenAPI 直接拉），架构上等价于多一个 backend，不重复展开。

2.2 AI 资料获取流水线

ingestion/pipeline.py 端到端串起以下 4 步：



2.3 为什么这套组合能替代传统爬虫

传统爬虫做法	本方案做法	收益
为每个站写 CSS selector / 正则	Jina Reader 直接转 markdown	不用维护 selector
字段映射写死在代码里	LLM 按 schema 抽取	改字段只改 schema 文档
只能识别显式字段	LLM 读出隐含信息 ("朱熹长房第 27 世后人 2009 创立"→ <code>brand_story</code> 节点 + 创立年份)	信息密度更高
单点失败整个挂掉	5 路搜索 + 3 路抓取 fallback	鲁棒性
价格更新要重写	高频字段不入向量库，运行时 Tool Use 实时查	数据新鲜度

2.4 多源冲突处理

同一字段多来源时按 `trust_level` 取最高（官网=5 > 旗舰店=4 > UGC=3 通常已被白名单拦掉）。功效相关说法只采集不直接使用，进入合规审核队列；未审核通过前 AI 一律走"不宣称功效"安全话术。

2.5 持续更新

.github/workflows/ingest.yml 每周日 03:00（北京时间）自动重跑流水线，diff 后提交 nodes.jsonl。价格/库存/物流不入向量库，运行时通过 API 实时拉取。

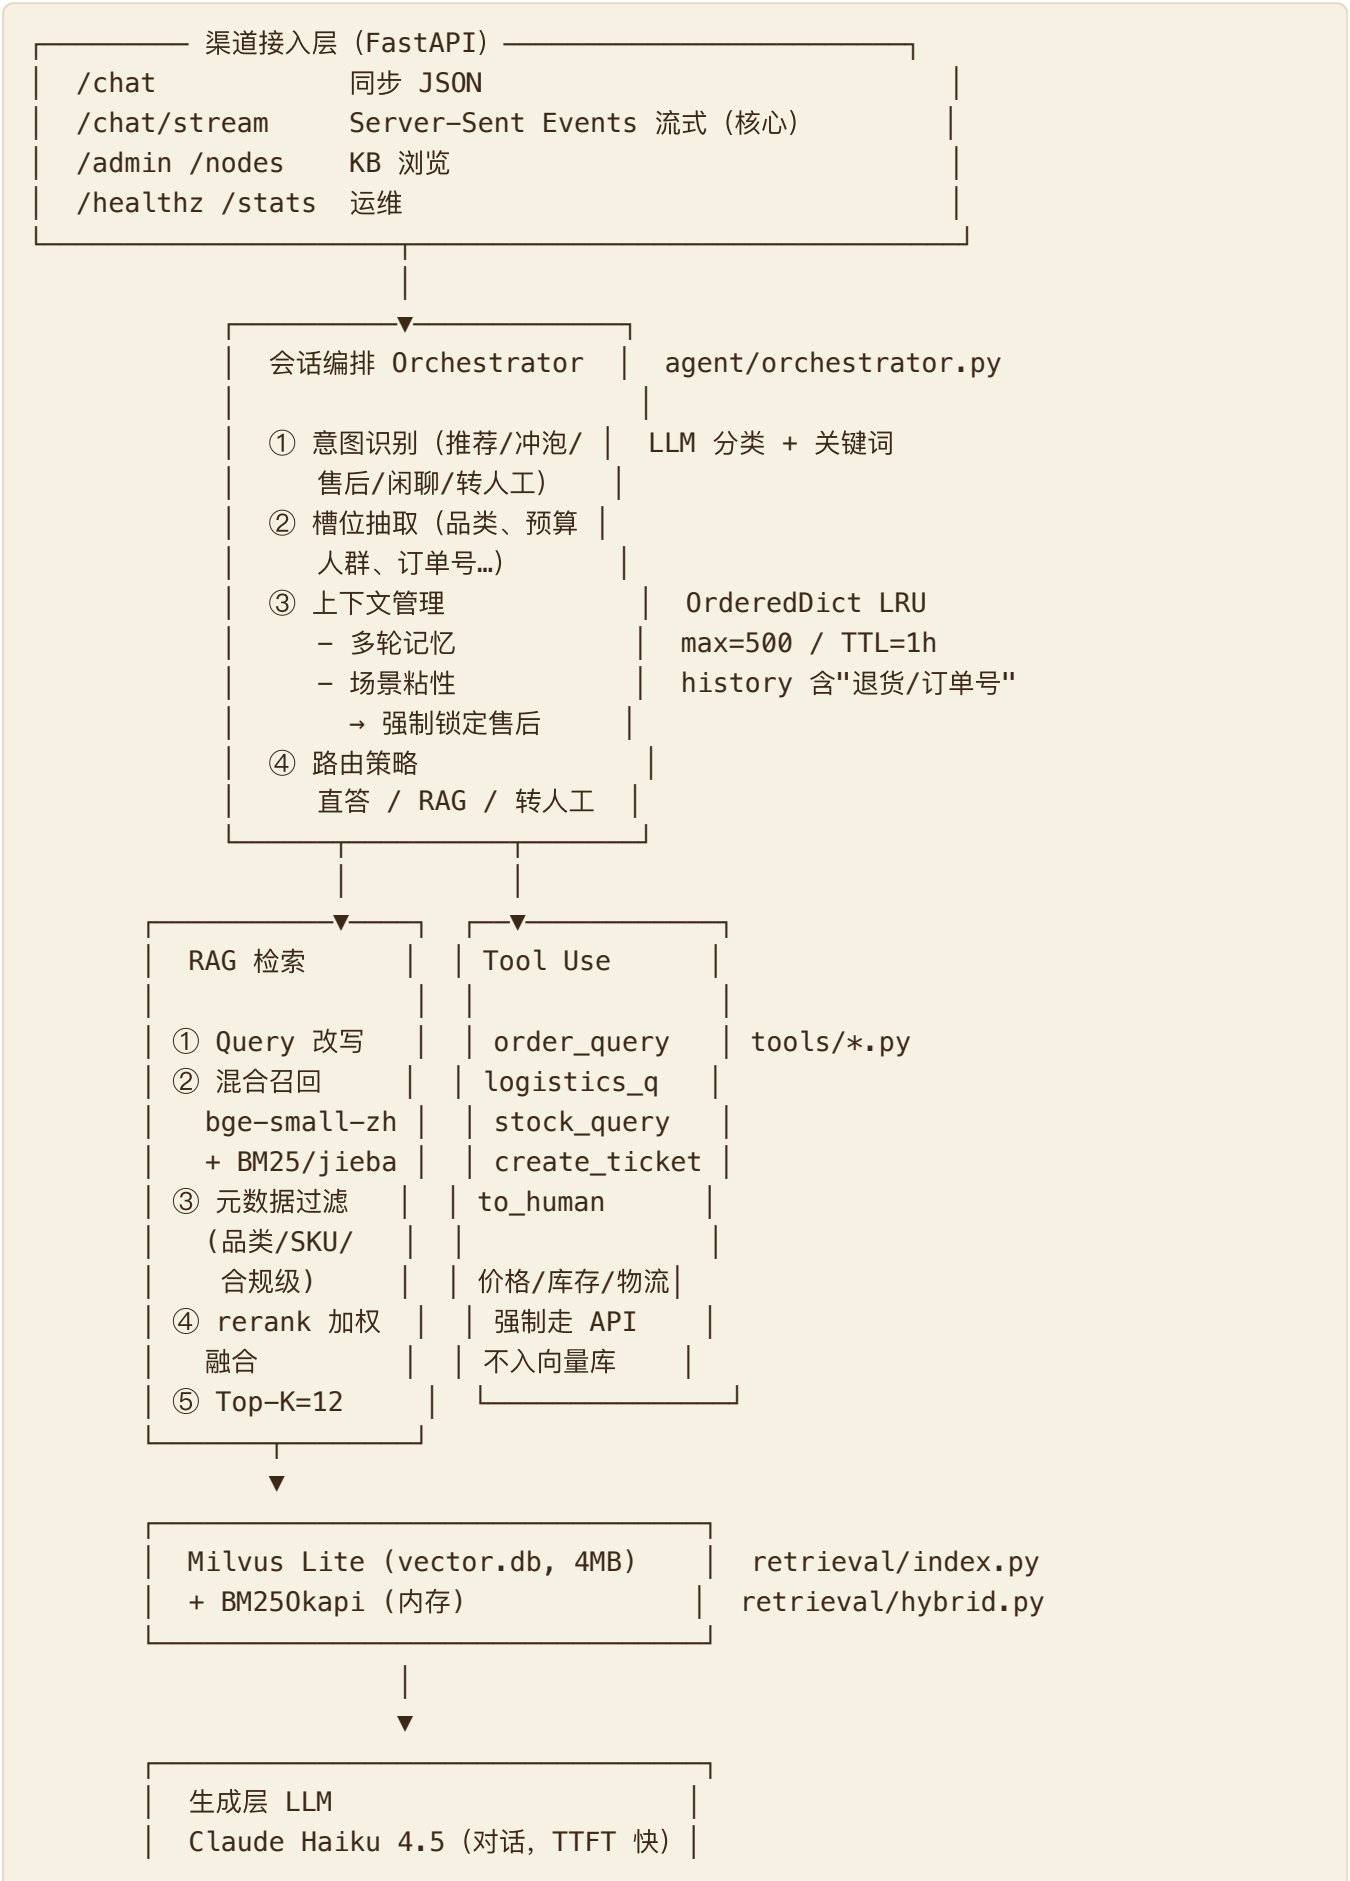
2.6 边界说明

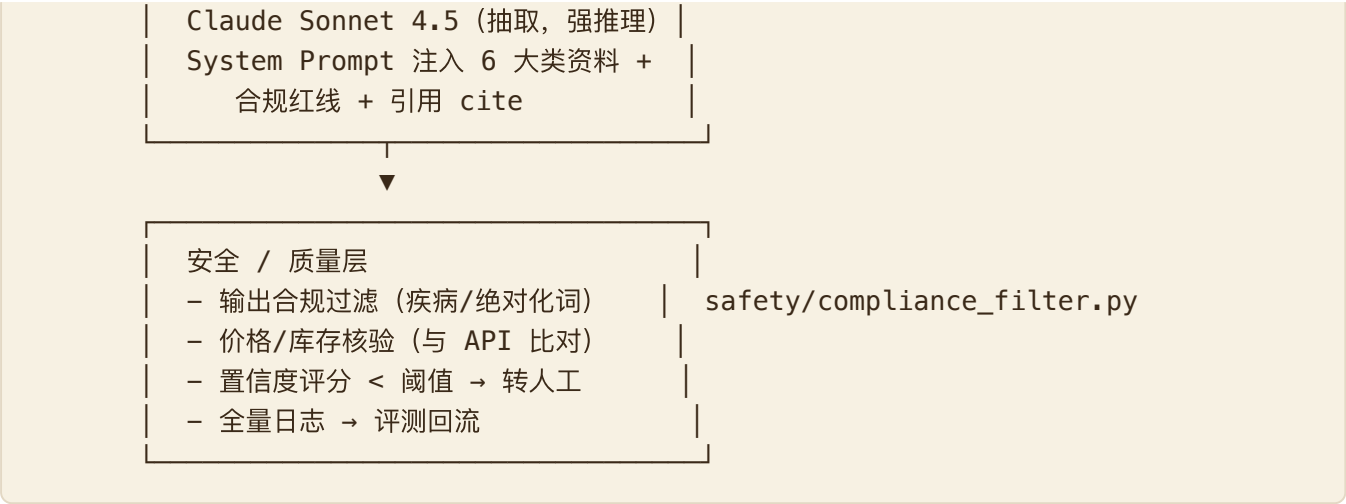
ximingcha.com 是品牌官网而非电商，全站 8 个 URL 没有"7 天无理由""破损补寄"等密集政策段落。本项目在采集端基于官网公开事实（全国客服热线 4008811977 + 400+ 线下门店）由 LLM 合成 3 条 commerce_aftersale_sop 节点，标注 trust_level=4 与原文区分；生产环境接入淘宝/京东/抖店铺 API 后可直接替换为真实政策。

三、基于 RAG 的 AI 客服问答系统架构

题目要求"线上客服有响应时长"。落地的可运行实现：FastAPI + SSE 流式 (app.py) + 单页 Web UI (web/index.html)，首字延迟约 2.5 秒。

3.1 总体架构





3.2 关键设计选型

模块	选择	理由
向量库	Milvus Lite	文件级 4MB, clone 即用; 生产换 Milvus 集群只改连接串
中文 embedding	bge-small-zh-v1.5 (512 维)	中文专名场景准确, 模型 90MB 对 CI 友好
关键词召回	BM25Okapi + jieba	解决向量对"肉桂/老丛"等专名的语义稀释问题
抽取模型	Claude Sonnet 4.5	schema 多节点抽取需推理, 便宜模型漏抽率高
对话模型	Claude Haiku 4.5	客服回复 ≤80 字, TTFT 约 2.5s 满足首响 SLA
LLM 接入	OpenRouter + Anthropic 双后端	一个 key 用所有模型, 部署友好
流式	SSE + anyio memory_object_stream	FastAPI async + 生产者线程桥接, TTFT 从 14.79s → 2.5s
会话记忆	OrderedDict LRU + TTL	内存型, max 500 会话 / 1h 过期, 无外部依赖

3.3 准确性保障 (5 道防线)

第 1 道 · 数据采集层 – host 白名单强约束, 只信官方源。 – LLM 抽取时合规红线写进 system prompt (疾病/治愈/抗癌/最/第一/独家 → 标 `sensitive: true` 并改写)。 – schema 校验失败 → `pending_review.jsonl` 不入主库。

第 2 道 · 检索层 – 向量 + BM25 混合召回, rerank 按 score 加权融合。 – 元数据强过滤 (用户问"白茶"时岩茶 chunk 直接被滤掉)。 – 同义词词典预扩展 ("大红袍/DHP"、"老丛/老枞")。

第 3 道 · Prompt 层（生成约束） – `prompts/system_base.md` 显式禁疗效宣称、禁绝对化、孕妇/服药一律建议咨询医生。 – "只用 `<context>` 里的资料；没有就直说'专属顾问跟您说更准'"，杜绝编造。 – 价格/库存/物流必须 Tool Use 取，不允许 LLM 自行生成数字。

第 4 道 · 输出过滤层 – `safety/compliance_filter.py` 双层正则： – 疾病词（治、抗、降三高、包治、抗癌） — 直接拦截。 – 绝对化用语（最、第一、国家级、独家、唯一） — 上下文敏感（避免误伤"110ml 盖碗最佳"等正常说法）。 – 命中即转人工 + 日志，不允许"洗白"违规话术。

第 5 道 · 评测与回流 – `eval/golden_set.jsonl` 黄金集 + `eval/run_eval.py` 通过 HTTP 跑回归。 – 在线指标：首响时长、解决率、转人工率、客诉率、合规违规数。 – 用户/坐席一键反馈"答错了" → badcase 池 → 周度修订知识库与 Prompt。

3.4 三档兜底分流

避免 AI 强答而出错： – **高置信度** → 直答； – **中等置信度** → AI 起草 + 人工 1 秒确认发送； – **低置信度 / 涉投诉/索赔/媒体身份** → 完全转人工，并把检索结果一并交付坐席。

四、Prompt 示例

实际文件： `prompts/system_base.md`（基座） + `prompts/recommend.md` + `prompts/brewing.md` + `prompts/aftersale.md`。

4.1 通用基座 Prompt（节选）

你是「烹茗」官方 AI 茶艺顾问「小茗」。

【风格】

- 简体中文，短：默认 ≤ 80 字，复杂问题最多 ≤ 150 字。
- 直接给答案，不铺垫"明白了/根据您的需求..."
- 反问最多 1 个最关键问题，不连续追问。
- 引用 SKU 时只附简短中文名（如「牛魁肉桂」），不附 doc_id。

【多轮对话】

- 持续跟踪当前场景。售后/退货流程中，用户后续简短消息（品名/订单号/感受/数字）一定是售后所需信息，绝不切换到产品推荐。

【知识使用】

- 只用 <context> 资料；资料没有时直说"这部分由专属顾问跟您说更准"。
- 价格/库存/物流走工具调用，不直接念检索里的旧数字。

【合规红线】

- 禁疗效宣称（治、抗、降三高 等）。
- 禁绝对化（最、第一、唯一、独家、国家级）。
- 孕妇/服药/失眠人群一律"建议咨询医生后再饮用"。

【转人工触发】

- 用户情绪激动 / 投诉 / 索赔 / 媒体身份 / 连续两轮未解决 → 转人工。

【输出】

直接纯中文，无 JSON、无 markdown 代码块。

每个场景的 system prompt 由"基座（4.1）+ 场景片段"拼接而成，运行时由 agent/orchestrator.py 根据意图识别结果注入对应片段。

4.2 场景一 · 产品推荐

场景 Prompt 片段 (prompts/recommend.md)：

【场景：选茶推荐】

- 信息够（已知品类+预算或场景）→ 直接推 1-2 款，每款 1 行卖点 + 1 行价格
- 信息不够 → 反问最关键的一项（送礼/自饮 二选一，或预算），只反问一次

禁止：

- 一次问 3 个问题（年龄、性别、口味、职位、预算.....）
- 用功效说服（"降血压"等）
- 推与口味偏好相反的产品

用户：想买点茶送领导，预算 800 左右，他平时喝岩茶多。

RAG 注入到 `<context>` 的 Top-K： - `product_sku` 正岩肉桂礼盒 250g · ¥788 · 三坑两涧拼配 - `product_sku` 老丛水仙礼盒 200g · ¥860 · 树龄 60 年+ - `product_scene` 商务送礼场景话术：领导款侧重"稳重、有故事感"

小茗（流式）：

送领导且常喝岩茶，给您挑两款都很稳：①「正岩肉桂礼盒 250g」¥788，桂皮香张扬，正岩骨韵足，礼盒带手提袋，体面有面子。②「老丛水仙礼盒 200g」¥860，60 年+老丛，木质丛香沉稳，更适合年长、喝茶资历深的领导。领导年龄段大概？我帮您定一款。

4.3 场景二 · 冲泡指导

场景 Prompt 片段 (prompts/brewing.md)：

【场景：冲泡指导】

直接给参数四件套：投茶量(g) / 水温(℃) / 出汤时间(秒) / 可冲次数。

品类要点：

- 岩茶/老白茶 → 100℃，前 3 道 5 秒快出
- 嫩芽红茶（金骏眉）→ 85-90℃
- 白毫银针 → 90℃，盖碗或玻璃杯
- 老白茶饼 → 可煮，沸水入壶煮沸转小火 3 分钟

苦/涩/淡 → 一句诊断（坐杯/投茶/水温/水质），再给修正参数。
一条建议即可，不要列 5 条。

用户：你们的肉桂我泡总是发苦，怎么办？

RAG 注入到 `<context>`： - `brewing_params` 肉桂 · 盖碗 110ml / 投茶 8g / 沸水 100℃ / 前 3 道 5 秒出汤 / 可冲 8 道 - `brewing_troubleshoot` 岩茶发苦三因：坐杯过久 / 投茶过多 / 水温不够

小茗：

多半是这三点之一：① 出汤太慢（前 3 泡 5 秒快出，超 10 秒就压苦）② 投茶过多（110ml 盖碗放 8g 即可）③ 水温不够（必须 100℃ 沸水）按「盖碗 110ml + 8g + 沸水 + 前 3 道 5 秒」试一次，回甘很明显。

4.4 场景三 · 售后处理（含多轮场景粘性）

场景 Prompt 片段 (prompts/aftersale.md)：

【场景：售后处理】

铁则：

1. 第一句话先共情致歉，不推诿。
2. 缺订单号/图片 → 一句话请用户补；已有 → 走政策。
3. 政策：质量异议（受潮/发霉/串味/虫蛀）→ 48h 内补寄或全额退款，运费我方承担。
4. 撬过的茶饼/紧压茶不支持 7 天无理由退换（食品类规定），但质量问题不受此限。
5. 命中升级关键词（315/曝光/起诉/媒体/赔我）→ 直接转人工，回复"已为您接通专属顾问"。

禁止：

- 擅自承诺超出政策（双倍/三倍赔付）
- 让用户出政策内运费
- 用户情绪激烈时还机械追问订单号—先安抚再请求信息

用户：我昨天收到的白牡丹饼，撬开里面有点发霉！

RAG 注入到 **<context>**：- **commerce_aftersale_sop** 食品质量异议 SOP：致歉 → 要订单号+清晰照片 → 核实后 48h 内补寄同款或全额退款，运费我方承担 → 单价 > 500 升级人工。

小茗：

非常抱歉。麻烦您：① 发一下【订单号】② 拍 2 张图：茶饼整体一张 + 霉点近距离一张（能看清生产日期更好）收到后立刻核实，按政策可【48h 内补寄同款】或【全额退款】，运费我们承担。

用户（下一轮）：白毫银针

⚠️ 多轮粘性是售后场景的关键。朴素 RAG 在此会切到"产品推荐"，错把用户当成在问新茶。agent/orchestrator.py 检测到历史含"退货/订单号/发霉"等关键词时，**强制锁定 aftersale prompt**，把"白毫银针"理解为"用户告诉我要退的茶是白毫银针"。

小茗（正确）：

收到，是白毫银针出了问题。是哪种不舒服——苦/涩/串味/发霉？方便的话发张产品照片，我现在就帮您走流程。

五、关键文件索引

```
ingestion/
  schema.py          ← 24 节点契约 (第 1 部分)
  sources.yaml       ← 种子 URL + host 白名单
  search_backends.py ← 5 路搜索 fallback
  fetch_backends.py  ← 3 路抓取 fallback (Jina/Tavily/Firecrawl)
  extract.py         ← LLM Schema 抽取
  pipeline.py        ← 端到端流水线 (第 2 部分)

retrieval/
  index.py           ← Milvus Lite + bge 入库
  hybrid.py          ← 向量 + BM25 混合检索 (第 3 部分)

agent/
  llm.py             ← OpenRouter / Anthropic 双后端 + 流式
  orchestrator.py    ← 会话编排 + 上下文意图锁定

prompts/
  system_base.md     ← 基座 (第 4 部分)
  recommend.md / brewing.md / aftersale.md ← 三场景

safety/
  compliance_filter.py ← 输出层正则双重过滤

eval/
  golden_set.jsonl   ← 黄金集
  run_eval.py        ← HTTP 回归脚本

app.py              ← FastAPI 入口 (含 SSE)
web/index.html      ← 单文件聊天界面
web/admin.html      ← KB 浏览 + pending review
.github/workflows/ingest.yml ← 周度自动刷新
Dockerfile / docker-compose.yml ← 一键部署
```